TP — Exploration de Gymnasium

1. Contexte et objectif

Ce TP prolonge le chapitre d'introduction à Gymnasium. Il vous demande d'explorer deux environnements très différents puis de construire progressivement plusieurs politiques de contrôle, depuis l'aléatoire jusqu'à des heuristiques guidées.

L'objectif n'est pas encore d'implémenter un agent optimal, mais de comprendre la bibliothèque « Gymnasium », d'étudier l'architecture d'un environnement et d'implémenter une politique.

2. Pré-requis et installation

Pré-requis techniques :

- Bases en Python : variables, conditions, boucles, fonctions, classes simples.
- Utilisation d'un notebook Jupyter ou JupyterLab.
- Connaissances élémentaires sur les structures de données Python.

Commandes d'installation recommandées :

```
pip install gymnasium
pip install "gymnasium[toy-text]"
pip install minigrid
```

3. Livrables attendus

- Date
- Un notebook complété et exécutable contenant le code demandé.
- Un court compte rendu intégré au notebook ou fourni séparément avec tableaux de résultats et réponses aux questions.
- Une conclusion synthétique comparant Taxi-v3 et MiniGrid-Empty-16x16-v0.

4. Consignes générales

- Commentez votre code avec sobriété mais suffisamment pour montrer votre raisonnement.
- Affichez les résultats utiles : récompense totale, nombre d'étapes, taux de succès, cause d'arrêt.
- Fixez des seeds lorsque cela est demandé afin d'améliorer la reproductibilité.
- Fermez toujours proprement les environnements avec env.close().
- Toute fonction de politique doit être clairement isolée dans le code.

5. Déroulement du TP

Partie A — Découverte de Taxi-v3

Tâches

- Créer l'environnement Taxi-v3.
- Afficher action_space, observation_space, spec et unwrapped.
- Exécuter quelques actions aléatoires et observer les retours de step().
- Produire un premier rendu texte si disponible.

Questions

1. Quel est le nombre d'actions possibles ?
2. Que représente l'observation dans Taxi-v3 ?
3. Pourquoi cet environnement est-il adapté à une première étude de politique ?

Partie B — Politique aléatoire sur Taxi-v3

Tâches

- Implémenter une fonction random_taxi_policy(obs, env).
- Lancer au moins 20 épisodes.
- Mesurer la récompense totale, le nombre d'étapes et le taux de succès.

Questions

1. Pourquoi les performances de cette politique restent-elles faibles ?
2. Quelles actions inutiles ou coûteuses apparaissent fréquemment ?

Partie C — Politique aléatoire contrainte sur Taxi-v3

Tâches

- Exploiter les informations disponibles pour éviter les actions manifestement invalides lorsque c'est possible.
- Comparer cette politique à la politique totalement aléatoire.
- Présenter un tableau comparatif sur 30 à 50 épisodes.

Questions

1. Pourquoi un simple filtrage des actions peut-il améliorer les résultats ?
2. En quoi cette politique reste-t-elle malgré tout limitée ?

Partie D — Politique heuristique simple pour Taxi-v3

Tâches

- Décoder l'état afin de récupérer les informations utiles.
- Écrire une politique guidée qui va vers le passager, effectue pickup, puis va vers la destination et effectue dropoff.

- Comparer cette politique aux deux politiques précédentes.

Questions

1. Quels éléments d'observation sont nécessaires pour construire cette politique ?
2. Quels cas particuliers doivent être traités explicitement ?

Partie E — Découverte de MiniGrid-Empty-16x16-v0

Tâches

- Créer l'environnement MiniGrid-Empty-16x16-v0.
- Afficher le type d'observation, les clés disponibles et l'espace d'action.
- Tester un rendu rgb_array et visualiser une frame.

Questions

1. Pourquoi MiniGrid est-il plus difficile à lire directement que Taxi ?
2. Qu'est-ce qui change du point de vue de l'observation et de l'exploration ?

Partie F — Politique aléatoire sur MiniGrid

Tâches

- Implémenter une politique aléatoire.
- Exécuter au moins 20 épisodes.
- Mesurer récompense cumulée, longueur d'épisode et taux de réussite.

Questions

1. Pourquoi l'aléatoire devient-il très inefficace dans une grille 16×16 ?
2. Quel rôle joue la rareté de la récompense ?

Partie G — Politique réflexe minimale sur MiniGrid

Tâches

- Implémenter une politique simple basée sur quelques règles locales.
- Par exemple : avancer si possible, sinon tourner selon une convention fixée.
- Comparer son comportement à celui de la politique aléatoire.

Questions

1. Pourquoi une politique purement réflexe peut-elle tourner en rond ?
2. Quelles informations manquent pour prendre de meilleures décisions ?

Partie H — Politique d'exploration avec mémoire minimale

Tâches

- Concevoir une politique avec état interne ou mémoire légère.
- Éviter autant que possible les répétitions immédiates.
- Comparer les résultats obtenus à ceux de la politique réflexe.

Questions

1. En quoi l'ajout d'une mémoire change-t-il la nature de la politique ?
2. Quels gains observez-vous sur les indicateurs quantitatifs ?

Partie I — Comparaison finale

Tâches

- Construire un tableau récapitulatif de toutes les politiques testées.
- Comparer Taxi-v3 et MiniGrid selon difficulté, lisibilité de l'observation, facilité de conception d'une politique et comportement observé.
- Rédiger une courte conclusion argumentée.

Question

1. Quel environnement vous semble le plus adapté pour introduire les politiques explicites ? Pourquoi ?

6. Questions de synthèse

1. Qu'est-ce qu'une politique dans le contexte de ce TP ?
2. Pourquoi Taxi-v3 permet-il de construire plus facilement une politique heuristique explicite ?
3. Pourquoi MiniGrid-Empty-16x16-v0 rend-il l'exploration plus difficile ?
4. Qu'avez-vous appris sur les limites des politiques codées à la main ?

7. Extension — Visualisation des politiques par images et vidéos

Cette partie complète l'analyse quantitative par une analyse visuelle du comportement des politiques sur un épisode.

Tâches

- Capturer quelques frames représentatifs d'un épisode sous forme d'images : début, milieu, fin.
- Utiliser le wrapper RecordVideo pour enregistrer au moins un épisode pour deux politiques différentes.
- Produire au moins une visualisation par images et une vidéo sur MiniGrid-Empty-16x16-v0. Le choix de Taxi-v3 comme environnement complémentaire est facultatif mais encouragé.
- Comparer visuellement au moins deux politiques parmi : politique aléatoire, politique réflexe, politique avec mémoire minimale, politique heuristique.

Questions

1. Quels comportements répétitifs, hésitations ou blocages remarquez-vous ?
2. Quelle politique paraît la plus cohérente à l'observation ?
3. Le rendu visuel confirme-t-il les indicateurs quantitatifs obtenus auparavant ?